



Università degli Studi di Ferrara

UNIVERSITÀ DEGLI STUDI DI FERRARA
CORSO DI LAUREA IN INFORMATICA

*Random Forest su immagini
satellitari per il riconoscimento e il
conteggio di piante*

Relatore:

Prof. Guido SCIAVICCO

Laureando:

Tobia SACCHETTO

ANNO ACCADEMICO 2025 – 2026

Indice

	Page
1 Introduzione	5
2 Conoscenze Preliminari	7
2.1 Cosa è l'analisi delle immagini satellitari	8
2.1.1 Dati di una fotografia satellitare	8
2.2 Introduzione al Machine Learning	9
2.2.1 Tipologie di apprendimento	11
2.2.2 Apprendimento Simbolico e Non Simbolico	13
2.2.3 Bontà del modello	14
2.2.4 Alberi Decisionali	15
2.2.5 Entropia	16
2.2.6 Guadagno Informativo	20
2.2.7 Foresta Casuale	20
2.2.8 Regressione Lineare	20
2.2.9 Normalizzazione e filtratura di un dataset	22
2.3 Metodi noti per la risoluzione del problema	24
3 Creazione del modello	27
3.1 Valutazione dei dataset	28
3.2 Valutazione degli approcci possibili	31

3.3	Implementazione del modello	31
3.3.1	Foresta Casuale su immagini	31
3.3.2	Regressione lineare su dimensione pixel	32
3.3.3	Modello NIR e SWIR	33
3.3.4	Modello solo NIR	33
4	Risultati	35
5	Conclusioni	37

Introduzione

In vasti terreni contare il numero di piante specifiche e identificarle è un problema. Si consideri, per esempio, una piccola azienda agricola con qualche ettaro di terreno e qualche migliaio di piante. Lo studio proposto in questa tesi espone un metodo per identificare e contare il numero di piante di avocado in un terreno aziendale tra la Spagna e il Portogallo attraverso tecniche di machine learning basate su immagini satellitari.

Lo scopo è fornire un algoritmo che attraverso un'immagine che sia in grado di individuare il numero di piante, e anche di conseguenza la dimensione totale della piantagione, per una rapida verifica del controllo del territorio agricolo.

Conoscenze Preliminari

In questo capitolo si affronterà le basi per comprendere successivamente appieno la struttura e i passaggi del lavoro svolto. Il seguente capitolo è suddiviso in 2 parti:

- La prima sezione spiega l'analisi di immagini satellitari, la loro tipologia e come è possibile riconoscere le piante.
- La seconda sezione introduce invece i concetti fondamentali del machine learning, con un'attenzione specifica sul machine learning simbolico che è stato usato nel progetto.

2.1 Cosa è l'analisi delle immagini satellitari

L'analisi delle immagini satellitari si riferisce al processo di estrazione di informazioni importanti dalle fotografie aeree scattate da satelliti orbitali. Questo campo combina la disciplina del telerilevamento con tecniche di apprendimento automatico (nello specifico computer vision) per interpretare grandi quantità di dati visivi.

2.1.1 Dati di una fotografia satellitare

All'interno di una fotografia comune (banalmente anche quella scattata dai telefoni), è possibile ricavarne i colori attraverso la codifica RGB che sta per Red (Rosso), Green(Verde) e Blue(Blu). Attraverso la combinazione di questi 3 valori si possono ricreare tutti i colori dello spettro visibile (osservabile con gli occhi). Inoltre, nelle immagini satellitari, vi sono anche i canali infrarosso quali RedEdge, NIR e SWIR. Si mostra una tabella 2.1 di alcune frequenze d'onda della radiazione elettromagnetica. Ad ogni frequenza appartiene una categoria. Si mostra anche un'immagine 2.1 che illustra lo spettro della luce visibile e dell'infrarosso.

Tipologia	Lunghezza d'onda
Viola	$\sim 380 - 450nm$
Blu	$\sim 450 - 495nm$
Verde	$\sim 495 - 570nm$
Giallo	$\sim 570 - 590nm$
Arancione	$\sim 590 - 620nm$
Rosso	$\sim 620 - 705nm$
RedEdge	$\sim 705 - 740nm$
NIR	$\sim 760 - 900nm$
SWIR	$\sim 1150 - 2350nm$

Tabella 2.1: tabella infrarosso

Attraverso l'infrarosso si può comprendere caratteristiche invisibili all'occhio umano per esempio lo stato di salute della vegetazione o i livelli di umidità del




Figura 2.1: spettro della radiazione visibile e dell'infrarosso

suolo.

Per lavorare con questi tipi di immagini è stato usato il software open source QGIS. Queste immagini hanno un formato `.tiff` e i file con cui è stato lavorato sono chiamati `...6band.tiff` dove, in questo caso, `6band` sta per *Red + Green + Blue + RedEdge + NIR + SWIR*. I valori delle bande nei file `.tiff` satellitari vengono salvati come `float32`. Questo formato permette di rappresentare le variabili con la virgola mobile per avere una precisione maggiore, anziché l'utilizzo di numeri interi.

Un esempio di un'immagine satellitare, con `bbox` (bounding box) disegnate per indicare la pianta, è riportata 2.2. Le `bbox` vengono salvate in file `.geojson`. All'interno di questo file ogni riga appartiene ad una singola `bbox` e ogni riga contiene le coordinate dei punti che formano il poligono (cioè la `bbox`).

Un'immagine è un insieme di pixel con coordinate (x, y) dove x mi indica la posizione del pixel nell'immagine sull'asse delle ascisse (asse orizzontale) e y sull'asse delle ordinate (asse verticale). Ogni pixel, oltre alle coordinate di riferimento, ha un valore che indica l'intensità del rosso, uno del verde, uno del blu, uno del RedEdge, uno del NIR e uno del canale SWIR.

2.2 Introduzione al Machine Learning

Il machine learning è il sottoinsieme dell'intelligenza artificiale (AI) basato su algoritmi in grado di "apprendere" i modelli dei dati di addestramento e, successivamente, fare previsioni accurate sui nuovi dati. Questa capacità di riconoscimento dei modelli consente ai modelli di machine learning di prendere decisioni o fare previsioni senza istruzioni esplicite e codificate.



Figura 2.2: Immagine satellitare con identificazione piante

Si definisce dati di addestramento o training data una parte di dati di un dataset che verrà usata per allenare il modello. Il dataset viene definito come un insieme di dati organizzati ($X = x_1, \dots, x_n$), dove a ogni elemento facente parte di esso, detto istanza o sample, rappresenta una misurazione di un certo fenomeno di interesse. Un esempio di un dataset potrebbe essere quello di una farmacia

Esempio	Farmaco	Categoria	Prezzo	Disponibilità
x_1	Tachipirina 1000 mg	Analgesico	7.50	Disponibile
x_2	Aspirina 500 mg	Antinfiammatorio	5.20	Disponibile
x_3	Moment 200 mg	Antidolorifico	6.80	Esaurito
x_4	Augmentin 875 mg	Antibiotico	12.40	Disponibile
x_5	Enterogermina	Probiotico	9.90	Disponibile
x_6	Benagol Gola	Pastiglie gola	4.30	Disponibile
x_7	Voltaren Gel	Antinfiammatorio	10.50	Esaurito
x_8	Zyrtec 10 mg	Antistaminico	8.70	Disponibile

Tabella 2.2: Esempio di dataset relativo ai prodotti di una farmacia

2.2.1 Tipologie di apprendimento

Possiamo distinguere i modelli in 3 principali tipi di apprendimento automatico:

- **Apprendimento Supervisionato:**

Nel dataset oltre all'input x_i viene associato (ad ogni input x_i) un output y_i . Si riporta una tabella esempio 2.3 come la precedente. In questo caso y_i indica se deve essere comprato oppure no il farmaco dal grossista.

Input	Output: Comprare?
x_1	$y_1 = SI$
x_2	$y_2 = NO$
x_3	$y_3 = NO$
x_4	$y_4 = SI$
x_5	$y_5 = SI$
x_6	$y_6 = NO$
x_7	$y_7 = SI$
x_8	$y_8 = SI$

Tabella 2.3: Esempio di coppie di un dataset

Il modello osserva coppie di input-output $((x_1, y_1), \dots, (x_n, y_n))$ e apprende una funzione (chiamata $\hat{h}$) che dato l'input (x_i) , il valore della funzione $\hat{h}(x)$ cerca di farlo avvicinare all'output corretto (y_i) . Per esempio, gli input potrebbero essere immagini ottenute da una fotocamera, ognuna accompagnata da un output che indica “bus” o “pedone” e così via. Un output come questo è chiamato etichetta. Nel nostro esempio l'output è se il farmacista dovrebbe comprarlo dal grossista oppure no, mentre le etichette sono Farmaco, Categoria, Prezzo e Disponibilità. Una funzione è dato un input x_i si ricava il risultato. Per esempio la funzione

$$h(x_i) = y_i \quad (2.1)$$

$$h(x_i) = 2x_i + 3 \quad (2.2)$$

$$h(3) = 2 \cdot 3 + 3 = 9 \quad (2.3)$$

Tuttavia, nel machine learning la forma della funzione $(2x + 3)$ non viene fissata in anticipo: non la conosciamo. Questa è calcolata automaticamente a partire dai dati di addestramento.

- **Apprendimento Non Supervisionato:**

Il modello apprende i pattern dall'input (x_i) senza alcun feedback esplicito (y_i) . L'attività di apprendimento non supervisionato più comune è il clustering: individuare cluster potenzialmente utili di esempi di input. Per esempio, un sistema di visione artificiale, osservando milioni di immagini prese da Internet, è in grado di identificare un ampio cluster di immagini simili

che una persona chiamerebbe gatti. Per esempio nell'immagine sottostante 2.3 i puntini in rosso sono i gatti, in verde le piante e in blu i pesci.




Figura 2.3: Rappresentazione di un cluster di un dataset

- **Apprendimento Rinforzato:**

L'apprendimento avviene grazie ad una serie di rinforzi: il modello impara da risposte positive o negative sul risultato. Ad esempio, dopo una partita a un gioco scelto, possono essere assegnati premi per la vittoria o punizioni per la sconfitta in base a come ha giocato il modello. Il gioco viene ripetuto e le azioni e scelte prese vengono progressivamente alterate dal modello in modo che questo ricerchi una ricompensa.

In questa tesi si andrà a lavorare con la tipologia di apprendimento supervisionato.

2.2.2 Apprendimento Simbolico e Non Simbolico

Il machine learning simbolico è un approccio all'apprendimento automatico che si basa sulla rappresentazione esplicita della conoscenza, tramite simboli (cioè segni che indicano entità, categorie e relazioni che vogliamo rappresentare (ad esempio gatto, essere vivente, appartiene a)), regole logiche espresse tipicamente

come implicazioni (se succede questo, allora...) e inferenza (ragionamento deduttivo).

Un esempio di ragionamento deduttivo è il seguente: a partire da regole generali e da fatti specifici, una macchina deduce una conclusione logicamente necessaria (se è vero che **tutti i mammiferi allattano** e che **Fido è un mammifero**, allora deduco che **Fido allatta**).

L'apprendimento simbolico non neecessità di grandi quantità di dati per l'addestramento, ha un'alta trasparenza nelle decisioni (perché ogni ragionamento si può comprendere attraverso regole logiche) e ha limiti nella gestione di dati rumorosi o ambigui.

L'apprendimento simbolico si contrappone all'apprendimento statistico (ad esempio le reti neurali), basato su correlazioni numeriche estratte dai dati. Quest'ultimo ha bisogno di grandi quantità di dati nell'apprendimento, sono delle blackbox (dato un input si ha un output, ma non si conosce il ragionamento dietro) e è buono nella gestione di dati rumorosi o ambigui.

2.2.3 Bontà del modello

Per valutare se il modello è buono per il problema si neecessità di conoscere i seguenti parametri.

- F1-macro
- ROC-AUC
- Prec-macro
- Rec-macro
- Positivi Veri (PV_i): pixel correttamente predetti come positivi;
- Negativi Veri (NV_i): pixel correttamente predetti come negativi;
- Positivi Falsi (PF_i) - pixel negativi ma predetti positivi;
- Negativi Falsi (NF_i) - pixel positivi ma predetti negativi.

Da qui possiamo calcolare:

- $Precision_i$: proporzione dei pixel classificati come piante e che rappresentano effettivamente delle piante.

$$Precision_i = \frac{PV_i}{PV_i + PF_i}$$

- $Recall_i$: calcola la percentuale di obiettivi da riconoscere che sono stati riconosciuti.

$$Recall_i = \frac{PV_i}{PV_i + NF_i}$$

- $F1_i$: serve per valutare la qualità di un modello

$$F1_i = 2 \cdot \frac{Precision_i \cdot Recall_i}{Precision_i + Recall_i}$$

$$\text{Prec-macro} = \frac{1}{N} \sum_{i=1}^N Precision_i \quad (2.4)$$

$$\text{Rec-macro} = \frac{1}{N} \sum_{i=1}^N Recall_i \quad (2.5)$$

$$\text{F1-macro} = \frac{1}{N} \sum_{i=1}^N F1_i \quad (2.6)$$

2.2.4 Alberi Decisionali

Possiamo visualizzare la tabella 2.2 e 2.3 come un albero decisionale 2.4.

Un albero decisionale serve a risolvere problemi di regressione e di classificazione 2.3. Questo è una rappresentazione di una funzione che dato in input un vettore di valori x_i da un valore di output (una decisione) y_i . Ogni nodo interno all'albero corrisponde ad un attributo della tabella, mentre i nodi esterni (foglie) a delle decisioni ($y = SI$ $y = NO$). I rami etichettati con degli ipotetici valori dell'attributo (Es. **Antinfiammatorio**, **SI**, **NO**,...). Per ... intendiamo tutti gli altri elementi che non fanno parte di quella categoria e le diciture **Prob** e **Antibi** stanno per rispettivamente Probiotico e Antibiotico. Questo albero in particolare come possiamo osservare viene usato per una classificazione binaria ($y = 0$ o $y = 1$)($y = SI$ $y = NO$), ma possiamo avere più classi ($y = 0$, $y = 1$, $y = 2$)




Figura 2.4: Albero decisionale del dataset farmacia

2.2.5 Entropia

Possiamo costruire un gran numero di alberi semplicemente cambiando attributi dell'albero. Per scegliere gli attributi e l'ordine di questi con cui costruire l'albero usiamo il concetto di guadagno di informazione 2.2.6, definito in termini di entropia. L'entropia è la misura dell'incertezza di una variabile casuale.

L'unità di misura dell'entropia in questo caso (dato che stiamo usando un computer (che comunica attraverso 0 o 1)) è il bit.

Entropia di una singola variabile casuale

L'entropia di una variabile casuale discreta V con k elementi è definita come:

$$H(V) = - \sum_k P(v_k) \log_2 P(v_k)$$

Dove v_k sono i possibili valori che la variabile aleatoria V assume. Ognuno di questi valori ha una probabilità $P(v_k) \in [0, 1]$ di accadere. Inoltre $\sum_k P(v_k) = 1$. Per esempio il lancio di una moneta 4 volte. La moneta ha 2 possibilità eque (Testa o

Croce). Quindi V sarà un vettore lungo $k = 16$ che contiene tutte i possibili lanci:

$$V = \{TTTT, TTTC, TTCT, \dots, CCCC\} \quad (2.7)$$

$$P(v_k) = \left(\frac{1}{2}\right)^4 \quad (2.8)$$

$$P(V) = \left\{ \left(\frac{1}{2}\right)^4, \left(\frac{1}{2}\right)^4, \dots, \left(\frac{1}{2}\right)^4 \right\} \quad (2.9)$$

Ad esempio

$$P(v_k = TCTT) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{16} \quad (2.10)$$

$$H(V) = - \sum_{k=1}^{k=16} \frac{1}{16} \log_2 \frac{1}{16} = 4\text{bit} \quad (2.11)$$

Quindi per rappresentare un risultato o i risultati dei k elementi della variabile aleatoria V sono necessari 4 bit.

La probabilità di ottenere C o T è $\frac{1}{2}$ e da qui possiamo affermare che la probabilità di ottenere un qualsiasi lancio di moneta 4 volte ($P(v_k)$) è esattamente $\left(\frac{1}{2}\right)^4$.

Ora per esempio poniamo di avere una moneta truccata che dia T il $\frac{2}{3}$ dei lanci e C il restante $\frac{1}{3}$. Di conseguenza

$$P(v_k = TCTT) = \frac{2}{3} \cdot \frac{1}{3} \cdot \frac{2}{3} \cdot \frac{1}{3} = \frac{8}{81} \quad (2.12)$$

$$P(v_k = TCCT) = \frac{2}{3} \cdot \frac{1}{3} \cdot \frac{2}{3} \cdot \frac{1}{3} = \frac{4}{81} \quad (2.13)$$

$$P(v_k = TCCC) = \frac{2}{3} \cdot \frac{1}{3} \cdot \frac{2}{3} \cdot \frac{1}{3} = \frac{2}{81} \quad (2.14)$$

$$P(v_k = TTTT) = \frac{2}{3} \cdot \frac{1}{3} \cdot \frac{2}{3} \cdot \frac{1}{3} = \frac{16}{81} \quad (2.15)$$

$$P(v_k = CCCC) = \frac{2}{3} \cdot \frac{1}{3} \cdot \frac{2}{3} \cdot \frac{1}{3} = \frac{1}{81} \quad (2.16)$$

$$(2.17)$$

Per la sequenza TCTT, che contiene una sola C, si ottengono in totale 4 configurazioni distinte (ad esempio TCTT,CTTT,TTCT,TTTC). Analogamente, le sequenze con 2 C sono 4, quelle con 3 C sono anch'esse 4, mentre esistono un'unica

configurazione con 4 C (CCCC) e una con 0 C (TTTT). Quindi

$$\begin{aligned}
 H(V) &= - \sum_k P(v_k) \log_2 P(v_k) \\
 &= - \left(\left(\frac{8}{81} \log_2 \frac{8}{81} \right) \cdot 4 \right. \\
 &\quad + \left(\frac{4}{81} \log_2 \frac{4}{81} \right) \cdot 4 \\
 &\quad + \left(\frac{2}{81} \log_2 \frac{2}{81} \right) \cdot 4 \\
 &\quad \left. + \frac{16}{81} \log_2 \frac{16}{81} + \frac{1}{81} \log_2 \frac{1}{81} \right) = 3.2446
 \end{aligned}$$

Di conseguenza ci servono meno bit di informazione per rappresentare questo caso rispetto il precedente

Entropia Congiunta

Prese 2 variabili aleatorie discrete V e G è l'entropia della loro coppia (V, G) .

$$H(V, G) = - \sum_{v,g} P(v_k, g_k) \log_2 P(v_k, g_k)$$




Figura 2.5: Rappresentazione di $H(V, G)$. Questo l'insieme delle entropie delle variabili casuali V e G

Esempio: Consideriamo 2 variabili casuali binarie:

- V esito del primo lancio (Testa o Crouce)
- G esito del secondo lancio (Testa o Croce)

Poniamo che la moneta sia equa e indipendente. Quindi:

$$V = \{T, C\} \quad (2.18)$$

$$G = \{T, C\} \quad (2.19)$$

$$P(V) = P(G) = \left(\frac{1}{2}, \frac{1}{2}\right) \quad (2.20)$$

$$P(v_k, g_k) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4} \quad (2.21)$$

Dato che la moneta è equa e quindi la probabilità di avere T o C non cambia di conseguenza l'entropia congiunta è:

$$H(V, G) = - \sum_{v,g} P(v_k, g_k) \log_2 P(v_k, g_k) \quad (2.22)$$

$$= - \left(4 \cdot \left(\frac{1}{4} \log_2 \frac{1}{4} \right) \right) = 2\text{bit} \quad (2.23)$$

Entropia Condizionata

L'entropia condizionale $H(V|G)$ è la quantità di informazione necessaria per descrivere il valore di una variabile aleatoria V noto il valore di un'altra variabile aleatoria G . $H(V|G)$ è definita come

$$H(V|G) = \mathbb{E}_G[H(V|g)] = \sum_{v,g} P(v_k, g_k) \log \frac{P(g_k)}{P(v_k, g_k)} \quad (2.24)$$

$$= H(V, G) - H(G) \quad (2.25)$$

Poniamo che Dobbiamo trovare l'entropia $H(V|G)$ dell'esempio precedente:

$$H(V, G) = 2\text{bit} \quad (2.26)$$

$$H(G) = - \left(2 \cdot \left(\frac{1}{2} \log_2 \frac{1}{2} \right) \right) = 1\text{bit} \quad (2.27)$$

$$H(V|G) = H(V, G) - H(G) = 2 - 1 = 1\text{bit} \quad (2.28)$$

2.2.6 Guadagno Informativo

Il guadagno informativo IG serve per capire che attributo(o variabile aleatoria (V o G)) scegliere per un albero decisionale. La formula è:

$$IG(G|V) = H(G) - H(G|V)$$

Per esempio nel caso precedente si avrebbe

$$IG(G|V) = H(G) - H(G|V) = 1 - 1 = 0\text{bit}$$

Quindi il primo lancio V non dice niente del secondo G . Questo non porta informazione. Per la creazione degli alberi viene calcolata l'entropia su tutto il dataset G e poi per ogni attributo disponibile V_i viene calcolato $IG(G|V_i)$ e viene scelto quello con il guadagno più alto.

2.2.7 Foresta Casuale

Una Foresta Aleatoria (o Foresta Casuale) è un insieme di tanti alberi decisionali N . Inoltre questi alberi vengono allenati solo su una parte scelta a caso di tutto il dataset. Questa tecnica viene chiamata bagging. Ogni campione preso in questo modo viene chiamato campione bootstrap e viene estratto casualmente con reinserimento. Per ogni nodo di questi alberi viene scelto un sottoinsieme di attributi casuali su cui cercare lo split migliore. L'input anziché essere dato a un singolo albero viene dato a tanti alberi in parallelo. I risultati u_i di questi vengono valutati per l'intera Foresta come una media $\left(\frac{1}{N} \cdot \sum_{k=1}^N u_k\right)$ se si tratta di un problema di regressione, oppure come un voto di maggioranza se invece si tratta di un problema di classificazione.

2.2.8 Regressione Lineare

La Regressione Lineare viene definita come un adattamento ad una funzione lineare dei dati (punti).




Figura 2.6: A sinistra una Regressione Lineare Univariata (Retta). A destra una approssimazione NON Lineare (Curva lisciata)

Per chiarezza, la curva di regressione è stata creata interpolando solo 5 punti dall'insieme del dataset presi a intervalli regolari. Questo non altera la tendenza poichè la funzione tende a generalizzare bene l'andamento dei punti.

Dati un insieme di i punti con 2 variabili (x, y) , per esempio ($x = \text{Larghezza}, y = \text{Lunghezza}$) la regressione è costruire una funzione che adatta l'andamento dei punti. In questa tesi si affronterà la Regressione Lineare Univariata. Nella Regressione Lineare Univariata la funzione che adatta i punti è una retta. La retta viene definita tramite la formula del tipo

$$y = mx + q$$

m indica l'inclinazione della retta, mentre q è lo spostamento di quella retta sull'asse delle ordinate. Si vuole trovare la funzione f che approssimi la sequenza dei vari punti. Quindi date i coppie (x_i, y_i) questo problema si risolve utilizzando il Metodo Dei Minimi Quadrati.

$$m = \frac{i \cdot \sum x_i y_i - \sum x_i \cdot \sum y_i}{i \cdot \sum (x_i^2) - (\sum x_i)^2} \quad (2.29)$$

$$q = \frac{\sum y_i \cdot \sum (x_i^2) - \sum x_i \cdot \sum x_i y_i}{i \cdot \sum (x_i^2) - (\sum x_i)^2} \quad (2.30)$$

Di conseguenza si può costruire la precedente funzione f che dà il punto sull'ordinata y_i sapendo solo il punto sulle ascisse x_i .

$$f(x_i) = m \cdot x_i + q = y_i$$

Ulteriori approfondimenti sul Machine Learning si possono affrontare nel libro Russell 2010 o nella sua versione in italiano Russell e Norvig 2022

2.2.9 Normalizzazione e filtratura di un dataset

Per normalizzazione di un dataset si intende dare a un insieme di dati un range garantito. Per esempio si vuole che i Per farlo si usa la seguente formula: dato un insieme di dati X di numero i ,

$$x_i = \frac{x_i - \min(X)}{\max(X) - \min(X)}$$

Dove X è il vettore che contiene tutti gli x_i . Quindi

$$X = \{x_1, x_2, \dots, x_i\}$$

In questa tesi si utilizzeranno dei filtri. Nello specifico filtri di media locale e varianza locale tra i vari pixel. Si mostra una rappresentazione dei vari pixel 2.7. Supponiamo che X sia il vettore che contiene i valori dei pixel rosso.

a_{11}	a_{12}	a_{13}
a_{21}	a_{22}	a_{23}
a_{31}	a_{32}	a_{33}

Figura 2.7: Esempio pixel

Si pone per esempio la seguente griglia (3×3) di visualizzazione dei valori dei pixel di colore rosso e si pongono i seguenti valori:

$$a_{11} = 0.75; a_{12} = 0.75; a_{13} = 0.75; \quad (2.31)$$

$$a_{21} = 0.45; a_{22} = 0.25; a_{23} = 0.95; \quad (2.32)$$

$$a_{31} = 0.35; a_{32} = 0.25; a_{33} = 0.05; \quad (2.33)$$

Di conseguenza nel pixel a_{22} avrò la media effettuata da:

$$\text{media}_{3 \times 3, \text{rosso}}(a_{22}) = \frac{1}{i \cdot j} \cdot \sum_i \sum_j a_{ij} \quad (2.34)$$

$$= \frac{1}{3 \cdot 3} \cdot ((0.75 + 0.75 + 0.75) \quad (2.35)$$

$$+ (0.45 + 0.25 + 0.95) + (0.35 + 0.25 + 0.05)) \quad (2.36)$$

$$= 0.5056 \quad (2.37)$$

Quindi nel layer $\text{media}_{3 \times 3, \text{rosso}}$ avremmo nel pixel $a_{22} = 0.5056$. Nel caso si voglia calcolare la $\text{media}_{3 \times 3, \text{rosso}}$ nel pixel a_{11} . Per gestire i pixel nei bordi si specchiano i valori nei pixel. Si creano delle caselle virtuali $a_{00}, a_{01}, a_{10}, \dots$ all'interno delle quali verrà inserito il valore del pixel rosso adiacente. Quindi $a_{00} = a_{01} = a_{10} = a_{11} = 0.75$, per $a_{02} = a_{12} = 0.75$, per $a_{20} = a_{21} = 0.45$ e così via... Di conseguenza la media nel pixel a_{11} sarà

$$\text{media}_{3 \times 3, \text{rosso}}(a_{11}) = \frac{1}{i \cdot j} \cdot \sum_i \sum_j a_{ij} \quad (2.38)$$

$$= \frac{1}{3 \cdot 3} \cdot ((0.75 + 0.75 + 0.75) \text{ che sarebbe } (a_{00}, a_{01}, a_{02}) \quad (2.39)$$

$$+ (0.75 + 0.75 + 0.75) + (0.45 + 0.45 + 0.25)) \quad (2.40)$$

$$= 0.6278 \quad (2.41)$$

Nella figura la tecnica di fare una $\text{media}_{3 \times 3}$ o 7×7 si rappresenta con una sfocatura [2.10](#). Si mostrano degli esempi

La deviazione standard per il pixel a_{22} (in questo caso di colore rosso) è data dalla formula

$$\text{devstand}_{3 \times 3, \text{rosso}}(a_{22}) = \sqrt{\frac{1}{i \cdot j} \sum_i \sum_j (x_{ij} - \text{media}_{3 \times 3, \text{rosso}}(a_{22}))^2} \quad (2.42)$$

$$= \sqrt{\frac{1}{3 \cdot 3} \left((0.75 - 0.5056)^2 + (0.75 - 0.5056)^2 + (0.75 - 0.5056)^2 \right. \\ \left. + (0.45 - 0.5056)^2 + (0.25 - 0.5056)^2 + (0.95 - 0.5056)^2 \right. \\ \left. + (0.35 - 0.5056)^2 + (0.25 - 0.5056)^2 + (0.05 - 0.5056)^2 \right)} \quad (2.43)$$

$$= \sqrt{0.0824} \approx 0.2872 \quad (2.44)$$




Figura 2.8: Rappresen-
tazione della immagine
rosso,verde,blu




Figura 2.9: Rappresen-
tazione della deviazione
standard del colore rosso
in modo binario (bian-
co/nero)




Figura 2.10: Rappresen-
tazione della media3x3
del colore rosso in modo
binario (bianco/nero)

Anche in questo caso nel caso si voglia calcolare a_{11} i valori vengono specchiati come nel caso precedente, quindi

$$\text{devstand}_{3 \times 3, \text{rosso}}(a_{11}) = \sqrt{\frac{1}{i \cdot j} \sum_i \sum_j (x_{ij} - \text{media}_{3 \times 3, \text{rosso}}(a_{11}))^2} \quad (2.45)$$

$$= \sqrt{\frac{1}{3 \cdot 3} \left((0.75 - 0.6278)^2 + (0.75 - 0.6278)^2 + (0.75 - 0.6278)^2 \right. \\ \left. + (0.75 - 0.6278)^2 + (0.75 - 0.6278)^2 + (0.75 - 0.6278)^2 \right. \\ \left. + (0.45 - 0.6278)^2 + (0.45 - 0.6278)^2 + (0.25 - 0.6278)^2 \right)} \quad (2.46)$$

$$= \sqrt{0.0328} \approx 0.1812 \quad (2.47)$$

La rappresentazione visuale della deviazione standard sul rosso su un'immagine si rappresenta come un accentuamento del cambio di intensità del colore 2.12. Si visualizzano un'immagine per esempio:

2.3 Metodi noti per la risoluzione del problema

Il problema di identificare le potenziali piante data un'immagine (in questo caso satellitare) non è banale. Non si può dedurre che si riuscirà a identificare la pianta in maniera certa e di conseguenza è necessario procedere a valutare caso per caso




Figura 2.11: Rappresentazione del colore rosso in modo binario (bianco/nero)




Figura 2.12: Rappresentazione della deviazione standard del colore rosso in modo binario (bianco/nero)

se l'identificazione è possibile.

Alcuni articoli, come Yao et al. 2021, hanno usato una rete neurale (di tipologia CNN) per trovare una mappa di densità degli alberi dall'immagine. Il numero totale degli alberi si ottiene integrando tale mappa. Altri articoli, come Fu et al. 2017, usano una Foresta Casuale 2.2.7 pixel per pixel per mappare la vegetazione delle zone umide. È stata inoltre consultata la tesi Pampalone 2025 per avere un contesto sulla lavorazione pixel per pixel.

Creazione del modello

In questo capitolo si andrà ad analizzare i dati e la loro struttura e successivamente si faranno delle scelte riguardo la creazione del modello. infine si mostrerà la creazione del modello stesso usando il lavoro descritto nel capitolo precedente.

3.1 Valutazione dei dataset

Durante la ricerca per trovare dei dataset gratuiti utilizzabili per l'addestramento del modello oltre a quelli messi a disposizione dell'azienda si è trovato il dataset Faet et al. 2025 che tuttavia non contiene il canale SWIR e le cui immagini sono state scattate da un drone e non da un satellite. Si cercava infatti dei dataset differenti da quelli forniti dall'azienda per diversificare le fonti e di conseguenza migliorare la conoscenza del modello.

Per valutare la bontà dei dati e se un ipotetico classificatore è in grado di distinguere i vari pixel si sono costruiti i grafici dei valori delle bande. Si mostrano di seguito i plot. Nello specifico si sono create delle bbox di diverse tipologie:

- bbox per indicare le non piante
- bbox per indicare le piante avocado
- bbox per indicare le piante di un'altra tipologia (1)
- bbox per indicare le piante di un'altra tipologia (2)

Le bbox (Bounding Box) sono riquadri di ritaglio nell'immagine su cui si andrà a lavorare. Per ogni bbox di una tipologia si fa il plot dei pixel contenuti all'interno della bbox. Di seguito si mostrano i plot per quanto riguarda le bbox non piante e le bbox che contengono le piante avocado 3.1




Figura 3.1: Si mostrano i grafici RGB delle bbox degli avocado e dei non pianta

Di seguito si mostrano i plot delle bande dell'infrarosso (RedEdge, NIR, SWIR) 3.2:

Dato che alcuni valori (prossimi allo 0) rendono il grafico poco chiaro e difficile interpretare le differenze tra gli istogrammi, si è deciso di rimuovere questi valori in modo da rendere il grafico interpretabile.




Figura 3.2: Si mostrano i grafici infrarosso delle bbox degli avocado e dei non pianta

Come si evince dai grafici in quasi tutte le bande gli istogrammi sono quasi tutti sovrapposti. Si riesce a differenziare solo nelle 2 classi (avocado e non pianta) solo nelle bande dei grafici NIR e SWIR. Questa separazione, sebbene non netta, indica che le bande infrarosse potrebbero essere le più informative per un ipotetico classificatore.

Si mostrano anche i bbox delle piante di tipologia 1 e 2 NIR prese dalle immagini fornite dall'azienda [3.3](#) [3.4](#).




Figura 3.3: Si mostrano i grafici NIR delle bbox delle tipologie di piante 1 e 2




Figura 3.4: Si mostrano i grafici NIR delle bbox delle tipologie di piante 1 e 2 togliendo i valori vicino 0

Di seguito si mostrano i grafici [3.6](#) [3.5](#) anche per il campo SWIR sempre per le stesse tipologie.




Figura 3.5: Si mostrano i grafici SWIR delle bbox delle tipologie di piante 1 e 2




Figura 3.6: Si mostrano i grafici SWIR delle bbox delle tipologie di piante 1 e 2 togliendo i valori vicino allo 0

Come si può osservare dai seguenti grafici 3.6 3.5 3.3 3.4 tutte le tipologie di piante analizzate è possibile distinguere visivamente le distribuzioni di tutte le tipologie.

Si afferma inoltre lo sbilanciamento del dataset per le classi. Si riporta una tabella che mostra il numero di tipologie

Classe	Numero di Pixel
Sfondo	113 035
Tipologia 1	135 863
Tipologia 2	1 068
Tipologia 3	6 392
Tipologia 4	40 000

Tabella 3.1: Numero di campioni per ciascuna classe.

Questo afferma che le proporzioni del dataset non sono distribuite equamente tra il numero di pixel da confrontare tra le varie tipologie. Il che potrebbe portare a delle scarse performance del modello.

3.2 Valutazione degli approcci possibili

Per i compiti di classificazione nelle 3 tipologie di piante si è scelto di adottare una Foresta Casuale [2.2.7](#). Rispetto all'utilizzo di una CNN (Convolutional Neural Network) per la classificazione di ogni pixel, la Foresta Casuale offre maggiore interpretabilità dei dati, richiede un numero di dati minore rispetto una CNN per l'allenamento, è computazionalmente più leggera. In questo caso l'utilizzo di una CNN sarebbe un aggravio delle performance e un aumento della complessità generale.

Successivamente si andrà ad applicare una Regressione Lineare [2.2.8](#) per comprendere il numero di piante dato un agglomerato di pixel classificati pianta dalla Foresta Casuale.

Poichè il dataset Faet et al. [2025](#) lavora solo con la banda infrarossa NIR si è scelto di addestrare 2 Foreste Casuali. Una che lavorerà solo con la banda NIR e una che lavorerà sia con la banda NIR che con la banda SWIR.

3.3 Implementazione del modello

3.3.1 Foresta Casuale su immagini

Si è andati a creare delle features derivate: media3x3, media7x7, std3x3 e std7x7 per ogni banda disponibile (quindi NIR e SWIR). Nello specifico si crea un immagine .tiff con 10 bande (media3x3rosso, media3x3verde,...). Per costruire il dataset di addestramento, sono stati estratti i pixel all'interno delle bbox annotate per classe. I campioni così ottenuti vengono randomizzati per evitare correlazioni dovute all'ordine dei pixel. Infine si allena la foresta. Per entrambi i modelli è stato impostato un limite di 100 alberi per Foresta (infatti indipendentemente dal superamento di questa soglia la bontà del modello non aumentava) e non è stato impostato un vincolo in profondità per gli alberi decisionali. Infatti non vi erano grossi differenze tra le profondità degli alberi della foresta e la loro performance. Il dataset viene suddiviso in training set (80%), mentre il restante è il test set (20%). La foresta casuale viene addestrata sul training, mentre i suoi risultati vengono testati sul test set per valutare la bontà del modello.

Per l'implementazione del codice è stato usato Python utilizzando la libreria Scikit-learn per la creazione della Foresta.

3.3.2 Regressione lineare su dimensione pixel

Al termine della classificazione si avrà un elenco di pixel che la macchina ha valutato come `pianta`(di `tipologia 1,2,3`) o `non pianta`. Dato che una singola pianta è considerata come un agglomerato di pixel `pianta`(di una `singola tipologia`), cioè un gruppo di pixel adiacenti, per risalire al numero di piante è necessario lavorare sugli agglomerati stessi.

Un agglomerato è definito come un insieme massimale di pixel di classe `pianta` appartenenti ad una singola tipologia, in cui ogni pixel è connesso ad almeno un altro pixel dell'insieme tramite adiacenza.

Per estrarre tutti gli agglomerati dall'immagine, si esegue una scansione completa dell'immagine. Per contare i pixel presente negli agglomerati si itera su tutti i pixel dell'immagine. Quando si trova un pixel `pianta` allora si esegue un BFS (Breadth First Search) dei pixel `pianta` vicini e si conta il numero dei pixel. Si è pensato di effettuare attraverso il BFS anche la conta i pixel del perimetro dell'agglomerato. Durante la ricerca per risolvere il problema si è pensato di usare una Regressione Lineare sugli agglomerati di pixel per comprendere il numero di piante presenti in quell'insieme. Il plot della regressione per la `tipologia avocado` è il seguente: Le formule delle rette di regressione trovate per l'area e il perimetro per la `tipologia avocado` sono rispettivamente:

$$y = 0.00636x - 0.00812 \quad (3.1)$$

$$y = 0.0236x - 0.239 \quad (3.2)$$

Si è deciso che il modello seguirà per la `tipologia avocado` solo la regressione dell'area dell'agglomerato poichè ha una accuratezza maggiore ($R^2 = 0.991$) rispetto il perimetro ($R^2 = 0.968$)

Si fa presente che la seguente regressione funziona solo se 1 pixel ha una singola pianta. Nel caso ci fossero delle piante annidate e che quindi 1 pixel contiene delle piante di varie tipologie la regressione andrebbe ad approssimare il numero di piante in modo grossolano ed errato.




Figura 3.7: Visualizzazione del grafico con in arancione i punti che indicano il numero dei pixel di un agglomerato e in blu i punti del numero di pixel come perimetro dell'agglomerato

3.3.3 Modello NIR e SWIR

Nel modello con NIR e SWIR si è andati ad usare entrambe le bande con un totale di 10 canali. Questo è stato allenato con solo dataset di un'immagine satellitare fornita dall'azienda con risoluzione $30cm/px$.

3.3.4 Modello solo NIR

Nel modello con solo NIR si è andati ad usare solo la banda NIR con un totale di 5 bande. Questo modello è stato addestrando utilizzando lo stesso dataset del modello NIR e SWIR, però usando solo il canale NIR e il dataset Faet et al. 2025. La risoluzione satellitare del dataset fornito dall'azienda è di $30cm/px$. Non tutti i dataset sono normalizzati quindi si procederà con una normalizzazione della risoluzione. È noto inoltre che nel dataset Faet et al. 2025 è stato usato il drone DJI Mavic 3 Multispectral. Ha volato con quota 14 m di altezza. La formula per trovare la risoluzione dei pixel è:

$$GSD = \frac{H \cdot S_w}{f \cdot I_w}$$

Dove H è l'altezza in volo, S_w è la larghezza del sensore, f è la focale e I_w è la larghezza immagine in pixel. Quindi la formula diventa:

$$GSD = \frac{14000mm \cdot 17.3mm}{12mm \cdot 5280px} = 0.38cm/px$$

Di conseguenza:

$$\text{Fattore di Scala} = \frac{GSD \text{ satellite}}{GSD \text{ drone}} = \frac{30cm/px}{0.38cm/px} = 78.95$$

In questo modo si è potuto comprendere quanto ridimensionare l'immagine del dataset Faet et al. 2025 in modo da uniformarle al dataset satellitare fornito dall'azienda.

Si ricorda che quindi questo modello troverà una tipologia di pianta in più ovvero gli aranci presenti solo nel dataset Faet et al. 2025.

Risultati

La tabella 4.1 riporta i risultati finali ottenuti dal modello addestrato sulle bande NIR e SWIR, valutata mediante cross-validazione sul training set. L'accuratezza complessiva ($F1$) del modello come riportato è pari a 0.89 con un buon bilanciamento tra le classi `tipologia1`, `tipologia2` e `sfondo`. La `tipologia3` mostra prestazioni minori ($F1 = 0.66$), principalmente a causa di una bassa *Recall* (0.58). Tale punteggio indica che molti pixel di questa classe vengono erroneamente assegnati ad altre.

Classe	Precision	Recall	F1-score	Support
sfondo	0.87	0.90	0.88	115 858
tipologia 1	0.91	0.89	0.90	135 863
tipologia 2	0.95	0.93	0.94	1068
tipologia 3	0.77	0.58	0.66	6392
accuracy			0.89	259 181
macro avg	0.87	0.82	0.84	259 181
weighted avg	0.89	0.89	0.89	259 181

Tabella 4.1: Risultati per classe — Cross-Validation sul Training Set (3 classi)

La tabella 4.2 mostra i risultati per il modello solo NIR. Si ricorda che il modello solo NIR trova una tipologia di pianta in più rispetto al modello NIR e SWIR. L'accuratezza scende a 0.85, e la perdita di accuratezza è particolarmente marcata per `tipologia2` ($F1 = 0.52$) e `tipologia3` ($F1 = 0.40$), le cui recall crolla rispettivamente a 0.41 e 0.30.

Classe	Precision	Recall	F1-score	Support
sfondo	0.83	0.87	0.85	113 035
tipologia 1	0.87	0.84	0.85	135 863
tipologia 2	0.74	0.41	0.52	1068
tipologia 3	0.61	0.30	0.40	6392
tipologia 4	0.91	0.95	0.93	40 000
accuracy			0.85	299 181
macro avg	0.79	0.67	0.71	299 181
weighted avg	0.85	0.85	0.85	299 181

Tabella 4.2: Risultati per classe — Cross-Validation sul Training Set (4 classi)

Dal confronto tra i risultati tra i due modelli emerge che la disponibilità della banda SWIR porta a un miglioramento significativo nella discriminazione delle specie vegetali, in linea con quanto osservato nell'analisi spettrale.

Si è visto inoltre che il modello tende a migliorare la `tipologia2` e `tipologia3` molto se si dispone di maggiori Support (ovvero di training set di `tipologia2` e `tipologia3`). Lo stesso si può dire per il modello NIR e SWIR con la `tipologia3`.

Un'ulteriore affermazione, che si può dire osservando i risultati è che il dataset è sbilanciato. Il risultato finale è un file `.geojson` dove vengono salvati gli agglomerati, che la Foresta Casuale identifica come pianta, e ogni agglomerato viene trasformato in un poligono(bbox) e gli viene assegnato un numero che identifica la tipologia di pianta, una stima del numero di piante presente al suo interno e l'area occupata.

Conclusioni

In questa tesi è stato mostrato un approccio al problema di classificazione (tramite una Foresta Casuale) e conteggio di piante (tramite una regressione per ogni tipologia di pianta) pixel per pixel di immagini satellitari. È stato scelto di creare una random forest che funziona usando solo la banda NIR e una che funziona usando NIR + SWIR. Il modello solo NIR raggiunge dei livelli di accuratezza maggiori di $F1 = 0.8$ per le tipologie `tipologia1` e `tipologia4` (quindi avocado e aranci). Invece, il modello NIR e SWIR funziona meglio con la classificazione di `tipologia1` e `tipologia2` e non ha la capacità di poter distinguere la `tipologia4`. Entrambe le Foreste Casuali create hanno dei limiti:

- Non riescono a risolvere in maniera precisa la `tipologia3` e la `tipologia2`, poiché il modello tende ad associare le piante ad un'altra tipologia.
- È presente uno sbilanciamento delle classi
- La regressione lineare funziona solo su piante che non si sovrappongono

Questo tipo di approcci non ha soluzioni empiriche universali ma ogni caso richiede un adattamento specifico. In futuro, si potrebbe creare un ampliamento del

dataset su cui lavorare e un'integrazione di bande infrarosso aggiuntive e un accrescimento di risoluzione per immagini su cui poter andare a lavorare. Un'ulteriore accortezza che eventualmente migliorerebbe il programma è l'aggiunta di una regressione lineare basata anche sulla sovrapposizione di piante per il conteggio. Soluzioni analoghe verranno sempre più utilizzate in futuro man mano che la tecnologia avanzerà e verranno sempre più usate tecnologie di precisione di larga scala per l'agricoltura.

Bibliografia

- Faet, Guillem Montalbán et al. (dic. 2025). *Dataset for orange fruit detection from UAV in citrus orchards*. Zenodo. DOI: [10.5281/zenodo.17866344](https://doi.org/10.5281/zenodo.17866344). URL: <https://doi.org/10.5281/zenodo.17866344>.
- Fu, Bolin et al. (2017). «Comparison of object-based and pixel-based Random Forest algorithm for wetland vegetation mapping using high spatial resolution GF-1 and SAR data». In: *Ecological Indicators* 73, pp. 105–117. ISSN: 1470-160X. DOI: <https://doi.org/10.1016/j.ecolind.2016.09.029>. URL: <https://www.sciencedirect.com/science/article/pii/S1470160X1630560X>.
- Pampalone, Giacomo (2025). «Progettazione e realizzazione di un software per l'individuazione (semi) automatica di tane di animali fossori in argini fluviali». Relatore: Prof. Guido Sciavicco. Correlatore: Dott. Alberto Paparella. Tesi di Laurea in Informatica. Università degli Studi di Ferrara.
- Russell, Stuart J (2010). *Artificial intelligence a modern approach*. Pearson Education, Inc.
- Russell, Stuart J e Peter Norvig (2022). *Intelligenza artificiale. Un approccio moderno*. Ediz. MyLab. it.
- Yao, Ling et al. (2021). «Tree counting with high spatial-resolution satellite imagery based on deep neural networks». In: *Ecological Indicators* 125, p. 107591. ISSN: 1470-160X. DOI: <https://doi.org/10.1016/j.ecolind.2021.107591>. URL: <https://www.sciencedirect.com/science/article/pii/S1470160X21002569>.