Università degli Studi di Ferrara

Università degli Studi di Ferrara

Corso di Laurea in Informatica

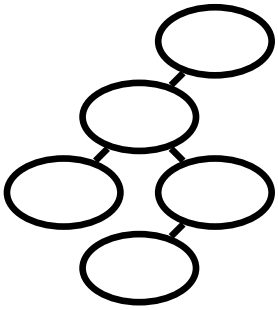

Il mio titolo della tesi in italiano

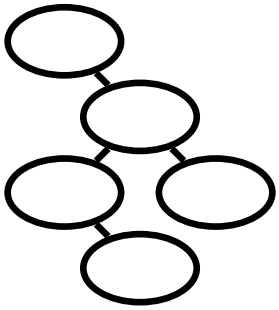

Relatore:
Prof. Guido Sciavicco

Laureando:
Tobia Sacchetto

Anno Accademico 2025 – 2026

Indice

Page

1 Introduzione **5**

2 Background **7**

2.1 Cosa è l'analisi delle immagini satellitari 8

2.1.1 Dati di una fotografia satellitare 8

2.2 Introduzione al Machine Learning 9

2.2.1 Tipologie di apprendimento 9

2.2.2 Apprendimento Simbolico e Non Simbolico 13

2.2.3 Bontà del modello 14

2.3 Metodi noti per la risoluzione del problema 15

Capitolo 1

Introduzione

In vasti terreni contare il numero di piante specifiche e identificarle è un problema. Basti pensare ad una piccola azienda agricola con qualche ettaro di terreno e qualche migliaia di piante. Lo studio proposto in questa tesi espone un metodo per identificare e contare il numero di piante di avvocado in un terreno aziendale tra la Spagna e il Portogallo attraverso tecniche di machine learning basate su immagini satellitari.
Lo scopo è fornire un algoritmo che attraverso un immagine mi identifichi il numero di piante, e anche di conseguenza la dimensione totale della piantagione, per una rapida verifica del controllo del territorio agricolo.

Capitolo 2

Background

In questo capitolo affronteremo le basi per comprendere successivamente appieno la struttura e i passaggi del lavoro. Il seguente capitolo è suddiviso in 2 parti:

- La prima in cui si spiega che cosa è l'analisi di immagini satellitari, il tipologia delle immagini su cui si è lavorato e come è possibile riconoscere.
- La seconda sezione introdurrà invece i concetti fondamentali del machine learning, con focus specifico sul machine learning simbolico che useremo nel progetto.

2.1 Cosa è l'analisi delle immagini satellitari

L'analisi delle immagini satellitari si riferisce al processo di estrazione di informazioni importanti dalle fotografie aeree scattate da satelliti orbitali. Questo campo combina la disciplina del telerilevamento con tecniche di apprendimento automatico (computer vision) per interpretare grandi quantità di dati visivi.

2.1.1 Dati di una fotografia satellitare

All'interno di una fotografia comune (anche quella scattata dai telefoni), è possibile ricavarne i colori RGB che stanno per Red (Rosso), Green(Verde) e Blue(Blu). attraverso la combinazione di questi 3 valori si può ricreare tutti i colori dello spettro visibile (osservabile con gli occhi). Tuttavia, nelle immagini satellitari, vi sono anche i canali infrarosso quali RedEdge, NIR e SWIR. Si mostra una tabella 2.1 di alcune frequenze d'onda della radiazione elettromagnetica. Ad ogni frequenza di questa appartiene una categoria. Si mostra anche un immagine 2.1 che mostra lo spettro delle luce visibile e dell'infrarosso.

Tipologia	Lunghezza d'onda
Viola	$\sim 380 - 450nm$
Blu	$\sim 450 - 495nm$
Verde	$\sim 495 - 570nm$
Giallo	$\sim 570 - 590nm$
Arancione	$\sim 590 - 620nm$
Rosso	$\sim 620 - 705nm$
RedEdge	$\sim 705 - 740nm$
NIR	$\sim 760 - 900nm$
SWIR	$\sim 1150 - 2350nm$

Tabella 2.1: tabella infrarosso

Attraverso l'infrarosso si può comprendere caratteristiche invisibili all'occhio umano per esempio lo stato di salute della vegetazione o i livelli di umidità del suolo.
Per lavorare con questi tipi di immagini è stato usato il software open source

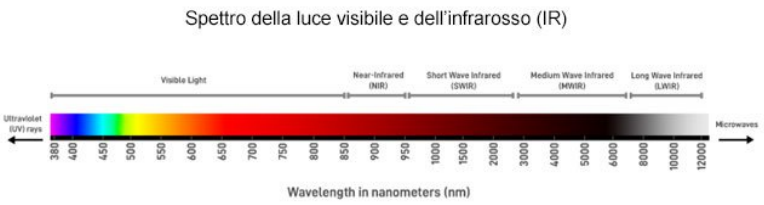

Figura 2.1: spettro della radiazione visibile e dell'infrarosso

QGIS. Queste immagini hanno un formato `.tiff` e i file con cui è stato lavorato sono chiamati `...6band.tiff` dove, in questo caso, `6band` sta per $Red + Green + Blue + RedEdge + NIR + SWIR$. Un esempio di un immagine satellitare, con bbox (bounding box) disegnate per indicare la pianta, è riportata 2.2. Un'immagine è un insieme di pixel con coordinate (x, y) dove x mi indica la posizione del pixel nell'immagine sull'asse delle ordinate (asse orizzontale) e y sull'asse delle ascisse (asse verticale). Ogni pixel, oltre alle coordinate di riferimento, ha un valore che mi indica l'intensità del rosso, uno del verde, uno del blu, uno del RedEdge, uno del NIR e uno del canale SWIR.

2.2 Introduzione al Machine Learning

Il machine learning è il sottoinsieme dell'intelligenza artificiale (AI) basato su algoritmi in grado di "apprendere" i modelli dei dati di addestramento e, successivamente, fare previsioni accurate sui nuovi dati. Questa capacità di riconoscimento dei modelli consente ai modelli di machine learning di prendere decisioni o fare previsioni senza istruzioni esplicite e codificate.
Si definisce dati di addestramento o training data una parte di dati di un dataset che verrà usata per allenare il modello. Il dataset viene denito come un insieme di dati organizzati $(X = x_1, ..., x_n)$, dove a ogni elemento facente parte di esso, detto istanza o sample, rappresenta una misurazione di un certo fenomeno di interesse. Un esempio di un dataset potrebbe essere quello di una farmacia

2.2.1 Tipologie di apprendimento

Possiamo distinguere i modelli in 3 principali tipi di apprendimento automatico:

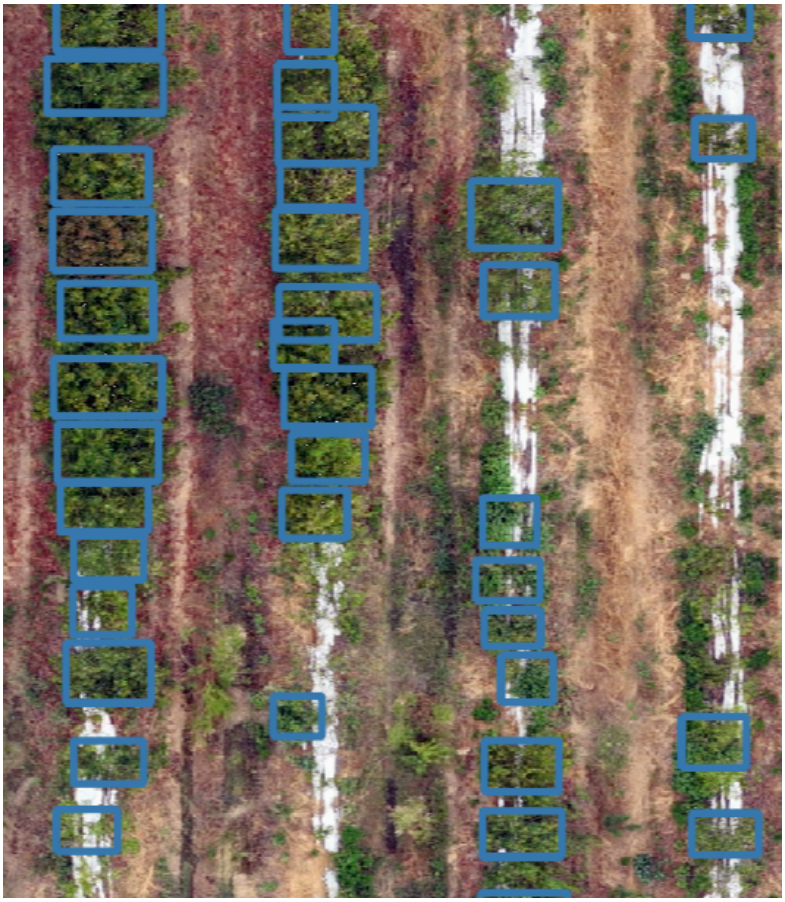

Figura 2.2: Immagine satellitare con identificazione piante

Esempio	Farmaco	Categoria	Prezzo	Disponibilità
x_1	Tachipirina 1000 mg	Analgesico	7.50	Disponibile
x_2	Aspirina 500 mg	Antinfiammatorio	5.20	Disponibile
x_3	Moment 200 mg	Antidolorifico	6.80	Esaurito
x_4	Augmentin 875 mg	Antibiotico	12.40	Disponibile
x_5	Enterogermina	Probiotico	9.90	Disponibile
x_6	Benagol Gola	Pastiglie gola	4.30	Disponibile
x_7	Voltaren Gel	Antinfiammatorio	10.50	Esaurito
x_8	Zyrtec 10 mg	Antistaminico	8.70	Disponibile

Tabella 2.2: Esempio di dataset relativo ai prodotti di una farmacia

- **Apprendimento Supervisionato**:
  Nel dataset oltre all'input x_i viene associato (ad ogni input x_i)un output y_i. Si riporta una tabella esempio come la precendete. In questo caso y_i indica se deve essere comprato oppure no il farmaco dal grossista. Il modello

Input	**Output**:Comprare?
x_1	$y_1 = SI$
x_2	$y_2 = NO$
x_3	$y_3 = NO$
x_4	$y_4 = SI$
x_5	$Y_5 = SI$
x_6	$y_6 = NO$
x_7	$y_7 = SI$
x_8	$y_8 = SI$

Tabella 2.3: Esempio di coppie di un dataset

osserva coppie di input-output $((x_1, y_1), ..., (x_n, y_n))$ e apprende una funzione (chiamata $\hat{h}$) che dato l'input (x_i), il valore della funzione $\hat{h}(x)$ cerca di farlo avvicinare all'output corretto (y_i). Per esempio, gli input potrebbero essere immagini ottenute da una fotocamera, ognuna accompagnata da un output che indica "bus" o "pedone" e così via. Un output come questo è chiamato etichetta. Nel nostro esempio l'output è se il farmacista dovrebbe comprarlo dal grossista oppure no, mentre le etichette sono Farmaco, Categoria, Prezzo

e Disponibilità Una funzione è dato un input x_i si ricava il risultato. Per esempio la funzione

$$h(x_i) = y_i \tag{2.1}$$

$$h(x_i) = 2x_i + 3 \tag{2.2}$$

$$h(3) = 2 \cdot 3 + 3 = 9 \tag{2.3}$$

Tuttavia, nel machine learning la forma della funzione $(2x + 3)$ non viene fissata in anticipo: non la conosciamo. Questa è calcolata automaticamente a partire dai dati di addestramento.

- **Apprendimento Non Supervisionato**:
  Il modello apprende i pattern dall'input (x_i) senza alcun feedback esplicito (y_i). L'attività di apprendimento non supervisionato più comune è il clustering: individuare cluster potenzialmente utili di esempi di input. Per esempio, un sistema di visione artificiale, osservando milioni di immagini prese da Internet, è in grado di identificare un ampio cluster di immagini simili che una persona chiamerebbe gatti. Per esempio nell'immagine sottostante i puntini in rosso sono i gatti, in verde le piante e in blu i pesci.

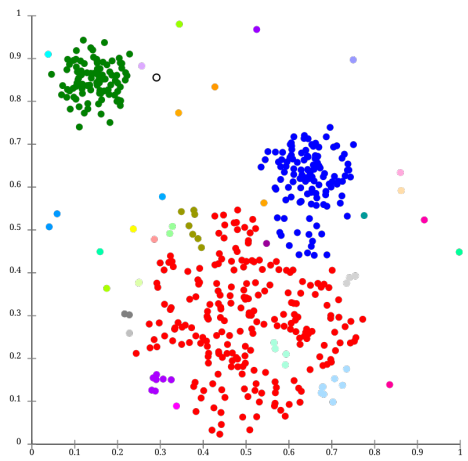

Figura 2.3: Rappresentazione di un cluster di un dataset

- **Apprendimento Rinforzato**:
  L'apprendimento avviene grazie ad una serie di rinforzi: il modello impara da risposte positive o negative sul risultato. Ad esempio, dopo una partita a un gioco scelto, possono essere assegnati premi per la vittoria o punizioni per la sconfitta in base a come ha giocato il modello. Il gioco viene ripetuto e le azioni e scelte prese vengono progressivamente alterate dal modello in modo che questo ricerchi una ricompensa.

In questa tesi si andrà a lavorare con la tipologia di apprendimento supervisionato.

2.2.2 Apprendimento Simbolico e Non Simbolico

Il machine learning simbolico è un approccio all'apprendimento automatico che si basa sulla rappresentazione esplicita della conoscenza, trammite simboli (cioè segni che indicano entità, categorie e relazioni che vogliamo rappresentare (ad esempio `gatto`, `essere vivente`, `appartiene a`)), regole logiche espresse tipicamente come implicazioni (se succede questo, allora...) e inferenza (ragionamento deduttivo).
Un esempio di ragionamento deduttivo è il seguente: a partire da regole generali e da fatti specifici, una macchina deduce una conclusione logicamente necessaria (se è vero che `tutti i mammiferi allattano` e che `Fido è un mammifero`, allora deduco che `Fido allatta`).
L'apprendimento simbolico non necessita di grandi quantità di dati per l'addestramento, ha un'alta trasparenza nelle decisioni (perché ogni ragionamento si può comprendere attraverso regole logiche) e ha limiti nella gestione di dati rumorosi o ambigui.
L'apprendimento simbolico si contrappone all'apprendimento statistico (ad esempio le reti neurali), basato su correlazioni numeriche estratte dai dati. Quest'ultimo ha bisogno di grandi quantità di dati nell'apprendimento, sono delle blackbox (dato un input si ha un output, ma non si conosce il ragionamento dietro) e è buono nella gestione di dati rumorosi o ambigui.

2.2.3 Bontà del modello

Per valutare se il modello è buono per il problema si neccessità di conoscere i seguenti parametri.

- F1-macro
- ROC-AUC
- Prec-macro
- Rec-macro

- True Positive (TP_i): pixel correttamente predetti come positivi;
- True Negative (TN_i): pixel correttamente predetti come negativi;
- False Positive (FP_i) - pixel negativi ma predetti positivi;
- False Negative (FN_i) - pixel positivi ma predetti negativi.

Da qui possiamo calcolare:

- $Precision_i$:proporzione dei pixel classicati come piante e che rappresentano effettivamente delle piante.

$$Precision_i = \frac{TP_i}{TP_i + FP_i}$$

- $Recall_i$: calcola la percentuale di obiettivi da riconoscere che sono stati riconosciuti.

$$Recall_i = \frac{TP_i}{TP_i + FN_i}$$

- $F1_i$:serve per valutare la qualità di un modello

$$F1_i = 2 \cdot \frac{Precision_i \cdot Recall_i}{Precision_i + Recall_i}$$

$$Prec - macro = \frac{1}{N} \sum_{i=1}^{N} Precision_i \tag{2.4}$$

$$Rec - macro = \frac{1}{N} \sum_{i=1}^{N} Recall_i \tag{2.5}$$

$$F1 - macro = \frac{1}{N} \sum_{i=1}^{N} F1_i \tag{2.6}$$

Ulteriori approfondimenti sul Machine Learning si posso affrontare nel libro Russell 2010 o nella sua versione in italiano Russell e Norvig 2022

2.3 Metodi noti per la risoluzione del problema

Alcune articoli come Yao et al. 2021 hanno usato una rete neurale (di tipologia CNN) per trovare una mappa di densità degli alberi dall'immagine. Il numero totale degli alberi si ottiene integrando tale mappa. Altri articoli come Fu et al. 2017 usano una Random Forest pixel per pixel per mappare la vegetazione delle zone umide.

Bibliografia

Fu, Bolin et al. (2017). «Comparison of object-based and pixel-based Random Forest algorithm for wetland vegetation mapping using high spatial resolution GF-1 and SAR data». In: *Ecological Indicators* 73, pp. 105–117. ISSN: 1470-160X. DOI: https://doi.org/10.1016/j.ecolind.2016.09.029. URL: https://www.sciencedirect.com/science/article/pii/S1470160X1630560X.

Russell, Stuart J (2010). *Artificial intelligence a modern approach*. Pearson Education, Inc.

Russell, Stuart J e Peter Norvig (2022). *Intelligenza artificiale. Un approccio moderno. Ediz. MyLab*. it.

Yao, Ling et al. (2021). «Tree counting with high spatial-resolution satellite imagery based on deep neural networks». In: *Ecological Indicators* 125, p. 107591. ISSN: 1470-160X. DOI: https://doi.org/10.1016/j.ecolind.2021.107591. URL: https://www.sciencedirect.com/science/article/pii/S1470160X21002569.